

BADANIE ALGORYTMÓW NAWIGACYJNYCH

Michał Bazan

Opiekun pracy:

dr inż. Dariusz Rzońca


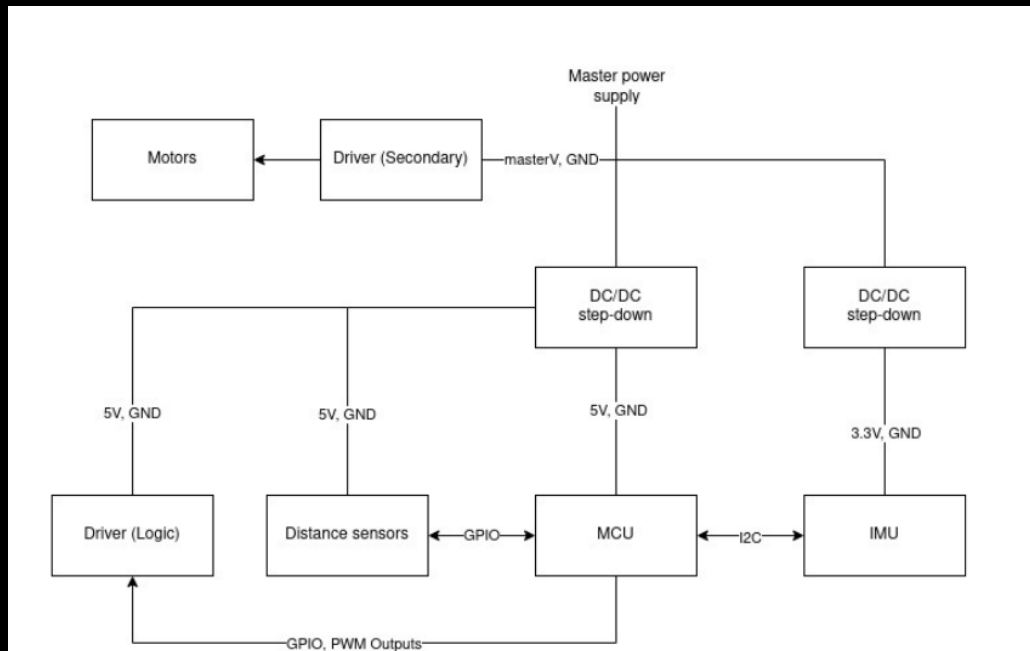
Cel pracy

- Badanie heurystycznych metod optymalizacji nastaw PID i porównanie z metodami klasycznymi
 - Badanie i porównanie statycznych algorytmów pod kątem wydajności obliczeniowej i dokładności nawigacji
 - Badanie i porównanie dynamicznych algorytmów pod kątem wydajności obliczeniowej i dokładności nawigacji
-

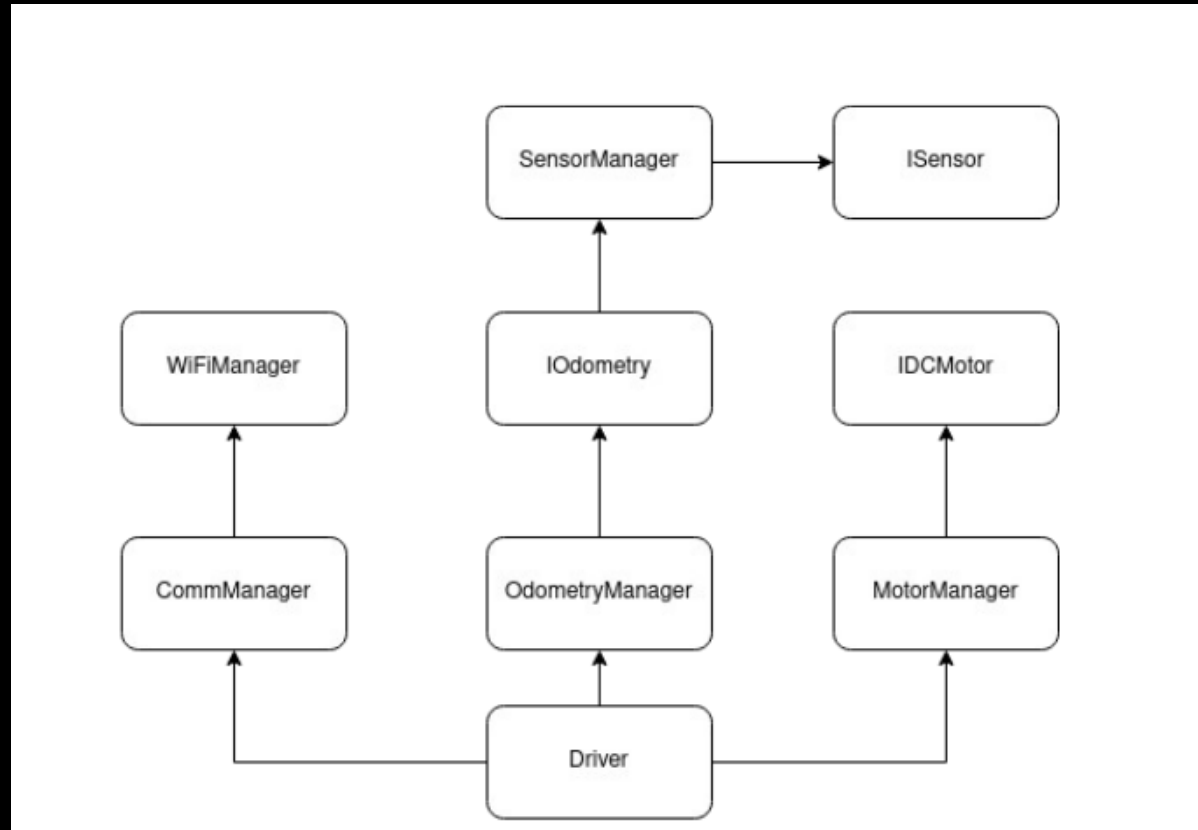
Zakres pracy

- Projekt i implementacja robota mobilnego zgodnie z procedurami ASPICE
 - Implementacja algorytmu genetycznego wyznaczającego nastawy PID, porównanie otrzymanych rezultatów z metodami klasycznymi
 - Implementacja oprogramowania testującego algorytmy statyczne i dynamiczne do wyznaczania trasy, porównanie pod kątem wydajności obliczeniowej i dokładności nawigacji
-


Implementacja robota mobilnego



Implementacja oprogramowania



Badanie metod heurystycznych do optymalizacji nastaw PID

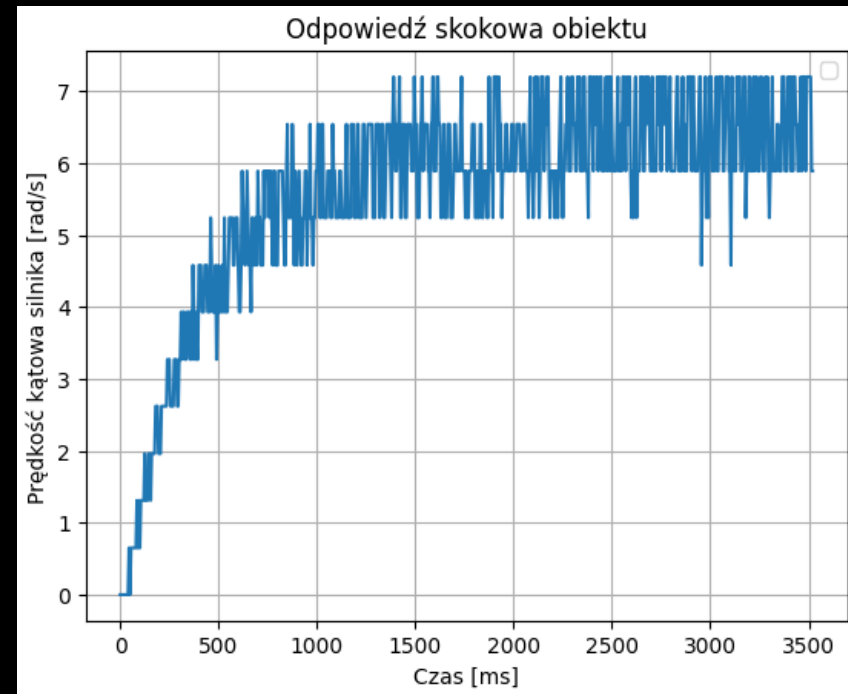


Stanowisko pomiarowe



Identyfikacja obiektu


- Obiekt – silnik szczotkowy DC
- Sygnał wejściowy - PWM o wypełnieniu 50%



Identyfikacja obiektu

Aproksymacja pierwszego rzędu:


- Wzmocnienie (K): 6.36
- Stała czasowa (T): 0.44



Wyznaczenie nastaw metodą Zieglera-Nicholsa

$K_p = 0.04$, $T_i = 0.695$, $T_d = 0.166$

Średni błąd względny regulacji: 7.43%



Opis eksperymentu – algorytm genetyczny

Algorytm został uruchomiony 3 razy z różnym zestawem parametrów:

- Populacja początkowa 100
- Populacja początkowa 200
- Populacja początkowa 300

Pozostałe parametry wspólne dla każdego eksperymentu:

- Maksymalna ilość generacji 25
- Prawdopodobieństwo krzyżowania 70%
- Prawdopodobieństwo mutacji 15%


Kryterium stopu:

Średni błąd regulacji najbliższy 0.

Algorytm **maksymalizuje** funkcję celu, dlatego wzór opisujący fitness danego osobnika został określony przez:

$$\frac{1}{\text{mean relative error}}$$

Wyniki działania algorytmu



Wyniki działania algorytmu

a) $K_p = 6.48$, $T_i = 2.93$, $T_d = 2.34$

Średni błąd względny regulacji: 1.96%

b) $K_p = 29.50$, $T_i = 14.54$, $T_d = 1.37$


Średni błąd względny regulacji: 6,60%

c) $K_p = 11.98$, $T_i = 1.59$, $T_d = 1.34$

Średni błąd względny regulacji: 6,41%


Wyniki działania algorytmu

$K_p = 6.48$, $T_i = 2.93$, $T_d = 2.34$




Wyniki działania algorytmu

$K_p = 29.50$, $T_i = 14.54$, $T_d = 1.37$



Wyniki działania algorytmu

$K_p = 11.98$, $T_i = 1.59$, $T_d = 1.34$



Porównanie algorytmu genetycznego z metodą klasyczną

- a) Metoda Zieglera-Nicholsa:
 - Czas regulacji ok 192ms
 - Niedoregulowanie, zbyt delikatny regulator
 - b) Algorytm genetyczny
 - Czasy regulacji ok 500ms
 - Satysfakcjonująca regulacja
-

Wnioski

- Ze względu na prostotę obiektu jakim jest silnik DC, różne nastawy regulatora są w stanie usatysfakcjonować stawiane przed nim wymagania,
 - Nastawy wyznaczone metodą klasyczną nie satysfakcjonują potrzeb, ponieważ występuje niedoregulowanie a ponadto jeden z silników nie reaguje na wymuszenie,
 - Nastawy wyznaczone algorytmem genetycznym oferują stabilną regulację kosztem dłuższego czasu ustalania obiektu,
 - Algorytm genetyczny po kilku epokach wyznacza lokalne optimum popadając w stagnację, dlatego przy bardziej złożonych obiektach warto rozważyć modyfikację parametrów algorytmu lub ponowną inicjalizację populacji jeśli najlepsze rozwiązanie jest daleko od kryterium stopu i nie zmienia się w kolejnych generacjach.
-